

# 第三章 观察性研究

罗珊珊

北京工商大学 数学与统计学院

因果推断课题组

# 目录

- ① 选择偏差
- ② 平均因果作用的识别
- ③ 两种简单的估计方法
  - 离散时的分层估计
  - 回归估计
- ④ 作业

# 目录

## ① 选择偏差

## ② 平均因果作用的识别


## ③ 两种简单的估计方法

离散时的分层估计

回归估计

## ④ 作业

# 观察性研究



实际研究中的数据经常并不是随机化的。

- 在观察性研究中，处理分配机制是未知的。
- 在观察性研究中， $Z$  不再随机化时，可能会：
  - $Z \not\perp X$ .  
这意味着处理组和对照组的协变量分布不再均匀。
  - $Z \not\perp \{Y(0), Y(1)\}$ .  
一些不可检验的假设将被引入用于 ATE 的识别。
- 在观察性研究中，相关一般不能表示因果。

# 记号

- 我们将所有的受试者记为  $i(i = 1, \dots, n)$ ，并用  $X_i$  表示个体  $i$  的基线协变量、 $Z_i$  表示个体  $i$  的原因变量（二值）、 $Y_i$  表示个体  $i$  的结果变量。
- 我们仍用记号  $Y_i(1)$  和  $Y_i(0)$  表示个体  $i$  在处理组和对照组下的潜在结果。
- 为简单起见，我们假设每个个体是独立同分布的（independent and identically distributed, IID）：

$$\{X_i, Z_i, Y_i(1), Y_i(0)\}_{i=1}^n \stackrel{\text{IID}}{\sim} \{X, Z, Y(1), Y(0)\}$$

因此，我们可以省略下标  $i$ 。

# 感兴趣的因果作用 I

我们感兴趣的因果作用包括：

- 平均因果作用（总体因果作用）：

$$\tau = E\{Y(1) - Y(0)\}$$

- 处理组平均因果作用（average causal effect of on the treated）：

$$\tau_T = E\{Y(1) - Y(0) \mid Z = 1\}$$

- 对照组平均因果作用（average causal effect on the control）：

$$\tau_C = E\{Y(1) - Y(0) \mid Z = 0\}$$

## 因果作用和随机化的重要性 I

- 通过期望的线性性质，我们有：

$$\begin{aligned}\tau_T &= E\{Y(1) \mid Z = 1\} - E\{Y(0) \mid Z = 1\} \\ &= E(Y \mid Z = 1) - E\{Y(0) \mid Z = 1\}. \\ \tau_C &= E\{Y(1) \mid Z = 0\} - E\{Y(0) \mid Z = 0\} \\ &= E\{Y(1) \mid Z = 0\} - E(Y \mid Z = 0).\end{aligned}$$

- 在上述  $\tau_T$  和  $\tau_C$  的两个公式中， $E(Y \mid Z = 1)$  和  $E(Y \mid Z = 0)$  可以直接从数据中观测得到
- 但  $E\{Y(0) \mid Z = 1\}$  和  $E\{Y(1) \mid Z = 0\}$  不能
- 后两者是反事实的，因为它们是与实际接受的处理相反的潜在结果的均值。

## 因果作用和随机化的重要性 II

- 简单的均值差异可以如下表示：

$$\begin{aligned}\tau_{\text{PF}} &= E(Y \mid Z = 1) - E(Y \mid Z = 0) \\ &= E\{Y(1) \mid Z = 1\} - E\{Y(0) \mid Z = 0\}\end{aligned}$$

通常对上述定义的因果作用具有偏差。例如，

$$\begin{aligned}\tau_{\text{PF}} - \tau_{\text{T}} &= \underbrace{E\{Y(0) \mid Z = 1\} - E\{Y(0) \mid Z = 0\}}_{\text{selection bias}}, \\ \tau_{\text{PF}} - \tau_{\text{C}} &= \underbrace{E\{Y(1) \mid Z = 1\} - E\{Y(1) \mid Z = 0\}}_{\text{selection bias}}.\end{aligned}$$

一般不为零，它们量化了选择偏差。它们衡量了处理组和对照组之间潜在结果均值的差异。



## 因果作用和随机化的重要性 III

- 但在随机化下, 由于  $Z \perp\!\!\!\perp \{Y(0), Y(1)\}$ , 会有


$$\tau_{\text{PF}} - \tau_{\text{T}} = E\{Y(0) \mid Z = 1\} - E\{Y(0) \mid Z = 0\} = 0,$$

$$\tau_{\text{PF}} - \tau_{\text{C}} = E\{Y(1) \mid Z = 1\} - E\{Y(1) \mid Z = 0\} = 0,$$

也就是  $\tau_{\text{PF}} = \tau_{\text{T}} = \tau_{\text{C}} = \tau$ .

- 从上面的讨论可以看出, 随机化的基本好处在于平衡处理组和对照组的潜在结果分布, 这比平衡观测到的协变量分布更为重要。
- 没有随机化, 选择偏差项可以特别大, 尤其是对于无界的结果变量。
- 这凸显了在观测性研究中进行因果推断的根本困难。

# 经典案例 – Berkeley 录取率 I



	All		Men		Women	
	Applicants	Admitted	Applicants	Admitted	Applicants	Admitted
Total	12,763	41%	8,442	44%	4,321	35%


实际研究中的数据经常  
并不是随机化的。

- $Z$ : 二值处理变量,  $A = 1$  代表男性,  $A = 0$  代表女性.
- $Y$ : 二值结果变量,  $Y = 1$  代表录取,  $Y = 0$  代表未录取.
- $L$ : 协变量, 表示专业.

ATE 可以如下估计吗?

$$\begin{aligned}\hat{\tau} &= \hat{E}(Y | Z = 1) - \hat{E}(Y | Z = 0) = \hat{\text{pr}}(Y = 1 | Z = 1) - \hat{\text{pr}}(Y = 1 | Z = 0) \\ &= 9\%.\end{aligned}$$

# 经典案例 – Berkeley 录取率 II



实际研究中的数据经常  
并不是随机化的。

Department	All		Men		Women	
	Applicants	Admitted	Applicants	Admitted	Applicants	Admitted
A	933	64%	<b>825</b>	62%	108	<b>82%</b>
B	585	63%	<b>560</b>	63%	25	<b>68%</b>
C	918	35%	325	<b>37%</b>	<b>593</b>	34%
D	792	34%	<b>417</b>	33%	375	<b>35%</b>
E	584	25%	191	<b>28%</b>	<b>393</b>	24%
F	714	6%	<b>373</b>	6%	341	<b>7%</b>
Total	4526	39%	2691	45%	1835	30%

Legend:

- greater percentage of successful applicants than the other gender
- greater number of applicants than the other gender

**bold** – the two 'most applied for' departments for each gender

(部分专业, 图源自 Wikipedia)

# 目录

## ① 选择偏差

## ② 平均因果作用的识别


## ③ 两种简单的估计方法

离散时的分层估计

回归估计

## ④ 作业

# 观察性研究 I




Rosenbaum and Rubin (1983) 提出的可忽略性假定是在观察性研究里评估因果作用最重要的假定.

## Assumption 1 (可忽略性, ignorability)

$$Z \perp\!\!\!\perp \{Y(0), Y(1)\} \mid X.$$

- $\text{pr}\{Z \mid X, Y(0), Y(1)\} = \text{pr}\{Z \mid X\}.$
- 在协变量的每个分层下, 处理分配机制可以被视为随机化.
- 随机化试验也满足可忽略性假设.
- 可忽略性又被称作无混杂 (unconfoundedness) 假设, 所有未观测的混杂不同时指向处理变量和结果变量.
- 该假设无法直接检验.

## 观察性研究 II




Rosenbaum and Rubin (1983) 提出的可忽略性假定是在观察性研究里评估因果作用最重要的假定.

### Assumption 2 (positivity, or overlap)

$$0 < \text{pr}(Z = 1 \mid X) < 1.$$

- 上述概率  $e(x) = \text{pr}(Z = 1 \mid X = x)$  常被称作倾向得分 (propensity score).
- 在协变量  $X$  的每一层里, 该假设都要求存在接受处理或接受对照的个体.
- 该假设可以直接检验.



Rosenbaum and Rubin (1983) 提出的可忽略性假定是在观察性研究里评估因果作用最重要的假定.

## Assumption 3 (强可忽略性, strong ignorability)

(i)  $Z \perp\!\!\!\perp \{Y(0), Y(1)\} \mid X$ ; (ii)  $0 < \text{pr}(Z = 1 \mid X) < 1$ .

在强可忽略性假定下, ATE 可以如下识别:

$$\begin{aligned}\tau &= E\{Y(1) - Y(0)\} \\ &= E\{E(Y(1) - Y(0) \mid X)\} \\ &= E\{E(Y(1) \mid X) - E(Y(0) \mid X)\} \\ &= E\{E(Y(1) \mid Z = 1, X) - E(Y(0) \mid Z = 0, X)\} \\ &= E\{E(Y \mid Z = 1, X) - E(Y \mid Z = 0, X)\}.\end{aligned}$$

如果不对混杂因素  $X$  进行调整, 将会导致有偏估计.

## 其他因果量的可识别性 I

在强可忽略性假设下，我们可以识别处理组平均因果作用  $\tau_T$  以及对照组平均因果作用  $\tau_C$ 。此外，我们也可以识别如下因果量：

- 分布因果作用 (distributional causal effect)：


$$\text{DCE}_y = \text{pr}\{Y(1) > y\} - \text{pr}\{Y(0) > y\}$$

以  $\text{pr}\{Y(1) > y\}$  为例，

$$\begin{aligned}\text{pr}\{Y(1) > y \mid X\} &= \text{pr}(Y > y \mid Z = 1, X), \\ \text{pr}\{Y(1) > y\} &= \mathbb{E}_X\{\text{pr}(Y > y \mid Z = 1, X)\}.\end{aligned}$$



## 其他因果量的可识别性 II



- 分位数因果作用 (quantile causal effect):

$$\text{QCE}_q = \text{quantile}_q\{Y(1)\} - \text{quantile}_q\{Y(0)\}$$

其中  $\text{quantile}_q(U)$  表示随机变量  $U$  对应的分布的第  $q$  个分位数点。

# 目录

## ① 选择偏差

## ② 平均因果作用的识别

## ③ 两种简单的估计方法

离散时的分层估计

回归估计

## ④ 作业

# 目录

## ① 选择偏差

## ② 平均因果作用的识别

## ③ 两种简单的估计方法

离散时的分层估计

回归估计

## ④ 作业

## 分层估计

当  $X$  是离散取值时, 假设取值范围为  $X = 1, \dots, K$ .

$$\begin{aligned}\tau &= E\{Y(1) - Y(0)\} \\&= E\{E(Y | Z = 1, X)\} - E\{E(Y | Z = 0, X)\} \\&= \sum_{k=1}^K \underbrace{E(Y | Z = 1, X = k)}_{\mu(1, k)} \text{pr}(X = k) - \sum_{k=1}^K \underbrace{E(Y | Z = 0, X = k)}_{\mu(0, k)} \text{pr}(X = k).\end{aligned}$$

- ①  $\mu(a, k)$  可以如下估计:  $\hat{\mu}(a, k) = \frac{\sum_{i=1}^n Y_i \mathbb{I}(Z_i = a, X_i = k)}{\sum_{i=1}^n \mathbb{I}(Z_i = a, X_i = k)}$ , 其中  $\mathbb{I}(\cdot)$  表示示性函数.
- ②  $\text{pr}(X = k)$  可以如下估计:  $\hat{\text{pr}}(X = k) = \frac{\sum_{i=1}^n \delta(X_i = k)}{n}$ .
- ③ 我们估计 ATE 如下,

$$\hat{\tau} = \sum_{k=1}^K \hat{\mu}(1, k) \hat{\text{pr}}(X = k) - \sum_{k=1}^K \hat{\mu}(0, k) \hat{\text{pr}}(X = k).$$

当  $X$  是维度很高或者连续时, 上述估计方法将不再适用

# 经典案例 – Berkeley 录取率 I

Department	All		Men		Women	
	Applicants	Admitted	Applicants	Admitted	Applicants	Admitted
A	933	64%	825	62%	108	82%
B	585	63%	560	63%	25	68%
C	918	35%	325	37%	593	34%
D	792	34%	417	33%	375	35%
E	584	25%	191	28%	393	24%
F	714	6%	373	6%	341	7%
Total	4526	39%	2691	45%	1835	30%

$$\hat{E}\{Y(1)\} = \underbrace{0.62}_{\hat{\mu}(1,1)} \times \underbrace{\frac{933}{4526}}_{\hat{\text{pr}}(X=1)} + \underbrace{0.63}_{\hat{\mu}(1,2)} \times \underbrace{\frac{585}{4526}}_{\hat{\text{pr}}(X=2)} + \dots + \underbrace{0.06}_{\hat{\mu}(1,6)} \times \underbrace{\frac{714}{4526}}_{\hat{\text{pr}}(X=6)} = 0.39.$$

$$\hat{E}\{Y(0)\} = \underbrace{0.82}_{\hat{\mu}(0,1)} \times \underbrace{\frac{933}{4526}}_{\hat{\text{pr}}(X=1)} + \underbrace{0.68}_{\hat{\mu}(0,2)} \times \underbrace{\frac{585}{4526}}_{\hat{\text{pr}}(X=2)} + \dots + \underbrace{0.07}_{\hat{\mu}(0,6)} \times \underbrace{\frac{714}{4526}}_{\hat{\text{pr}}(X=6)} = 0.43.$$

$$\hat{\tau} = \hat{E}\{Y(1)\} - \hat{E}\{Y(0)\} = -0.04$$

Association Does Not Imply Causation!

# 目录

## ① 选择偏差

## ② 平均因果作用的识别

## ③ 两种简单的估计方法

离散时的分层估计

回归估计

## ④ 作业

# 回归估计 I

- 除了分层估计以外，在实际研究中，最常用的分析方法是对观测到的结果运行 OLS（最小二乘）回归，即假设结果变量符合以下模型：

$$E(Y | Z, X) = \beta_0 + \beta_z Z + \beta_x^T X.$$

- 如果上述线性模型是正确的，那么我们有：

$$\begin{aligned}\tau(X) &= E(Y | Z = 1, X) - E(Y | Z = 0, X) \\ &= (\beta_0 + \beta_z + \beta_x^T X) - (\beta_0 + \beta_x^T X) \\ &= \beta_z,\end{aligned}$$

这意味着因果作用在协变量方面是均匀的。

## 回归估计 II

- 结合可忽略性假设，这意味着：

$$\tau = E\{\tau(X)\} = \beta_z,$$

从而线性模型  $Z$  前面的系数具有因果含义。这是线性模型最重要的应用之一。



## 回归估计 III

- 此外，我们可以进一步考虑由协变量引起的因果作用异质性，即考虑以下存在交互项的线性模型

$$E(Y | Z, X) = \beta_0 + \beta_z Z + \beta_x^T X + \beta_{zx}^T XZ$$

我们有：

$$\begin{aligned}\tau(X) &= E(Y | Z = 1, X) - E(Y | Z = 0, X) \\ &= (\beta_0 + \beta_z + \beta_x^T X + \beta_{zx}^T X) - (\beta_0 + \beta_x^T X) \\ &= \beta_z + \beta_{zx}^T X,\end{aligned}$$

## 回归估计 IV

- 由可忽略性假设，我们有：

$$\tau = E\{\tau(X)\} = E(\beta_z + \beta_{zx}^T X) = \beta_z + \beta_{zx}^T E(X).$$

- 因此， $\tau$  的估计量是  $\hat{\beta}_z + \hat{\beta}_{zx}^T \bar{X}$ ，其中  $\hat{\beta}_z$  是回归系数， $\bar{X}$  是  $X$  的样本均值。
- 如果我们对协变量进行中心化  $\bar{X} = 0$ ，那么估计量就是  $Z$  的回归系数。

## 回归估计 V

- 更为一般地，我们可以使用其他更复杂的模型来估计因果作用。
- 基于处理组和对照组的数据，我们可以分别构造两个估计量  $\hat{\mu}_1(X)$  和  $\hat{\mu}_0(X)$ ，我们可以通过如下矩约束条件求解参数  $\hat{\alpha}$ ,

$$E\{Y - \mu(Z, X; \hat{\alpha}) \mid Z, X\} = 0.$$

并构建以下估计量

$$\hat{\tau}_{\text{reg}} = \frac{1}{n} \sum_{i=1}^n \{\hat{\mu}(1, X_i) - \hat{\mu}(0, X_i)\},$$

值得注意的是，当  $\mu(Z, X; \alpha)$  被错误指定时， $\hat{\tau}_{\text{reg}}$  并不能相合估计  $\tau$ 。

## 回归估计 VI

- 针对二值的结果变量，我们可以使用 logistic 模型来拟合：

$$E(Y | Z, X) = \text{pr}(Y = 1 | Z, X) = \frac{e^{\beta_0 + \beta_z Z + \beta_x^T X}}{1 + e^{\beta_0 + \beta_z Z + \beta_x^T X}}$$

- 基于系数估计  $\hat{\beta}_0, \hat{\beta}_z, \hat{\beta}_x$ ，我们可以得到以下的平均因果作用估计量：

$$\hat{\tau} = n^{-1} \sum_{i=1}^n \left\{ \frac{e^{\hat{\beta}_0 + \hat{\beta}_z + \hat{\beta}_x^T X_i}}{1 + e^{\hat{\beta}_0 + \hat{\beta}_z + \hat{\beta}_x^T X_i}} - \frac{e^{\hat{\beta}_0 + \hat{\beta}_x^T X_i}}{1 + e^{\hat{\beta}_0 + \hat{\beta}_x^T X_i}} \right\}.$$

- 这个估计量不仅仅是 logistic 模型中处理变量的系数。它是所有系数以及协变量的经验分布的非线性函数。

## References I

Rosenbaum, P. R. and Rubin, D. B. (1983). The central role of the propensity score in observational studies for causal effects. *Biometrika*, 70(1):41–55.

# 本周作业

证明题：

- ① 证明处理组因果作用可识别
- ② 证明分布因果作用可识别或分位数因果作用可识别

上机作业：

- ① 计算所给数据的分层估计、或回归估计量

作业扫描成 pdf 发邮箱:smengchen@163.com