

# 第三章 观察性研究

罗珊珊


北京工商大学 数学与统计学院  
因果推断课题组

# 目录

## ① 观察性研究

## ② 作业

# 观察性研究




(ii) 观察性研究

实际研究中的数据经常并不是随机化的.

- 在观察性研究中, 处理分配机制是未知的.
- 在观察性研究中,  $A$  不再随机化时, 可能会:
  - $A \not\perp L$ .  
这意味着处理组和对照组的协变量分布不再均匀.
  - $A \not\perp (Y_0, Y_1)$ .  
一些不可检验的假设将被引入用于 ATE 的识别.
- 在观察性研究中, 相关一般不能表示因果.

# Yule-Simpson 悖论



(ii) 观察性研究

	All		Men		Women	
	Applicants	Admitted	Applicants	Admitted	Applicants	Admitted
Total	12,763	41%	8,442	44%	4,321	35%


- $A$ : 二值处理变量,  $A = 1$  代表男性,  $A = 0$  代表女性.
- $Y$ : 二值结果变量,  $Y = 1$  代表录取,  $Y = 0$  代表未录取.
- $L$ : 协变量, 表示专业.

实际研究中的数据经常  
并不是随机化的.

ATE 可以如下估计吗?

$$\begin{aligned}\hat{\tau} &= \hat{E}(Y | A = 1) - \hat{E}(Y | A = 0) = \hat{\text{pr}}(Y = 1 | A = 1) - \hat{\text{pr}}(Y = 1 | A = 0) \\ &= 9\%.\end{aligned}$$

# Yule-Simpson 悖论



(ii) 观察性研究

实际研究中的数据经常  
并不是随机化的。

Department	All		Men		Women	
	Applicants	Admitted	Applicants	Admitted	Applicants	Admitted
A	933	64%	<b>825</b>	62%	108	<b>82%</b>
B	585	63%	<b>560</b>	63%	25	<b>68%</b>
C	918	35%	325	<b>37%</b>	<b>593</b>	34%
D	792	34%	<b>417</b>	33%	375	<b>35%</b>
E	584	25%	191	<b>28%</b>	<b>393</b>	24%
F	714	6%	<b>373</b>	6%	341	<b>7%</b>
Total	4526	39%	2691	45%	1835	30%


Legend:

- greater percentage of successful applicants than the other gender
- greater number of applicants than the other gender

**bold** – the two 'most applied for' departments for each gender

(部分专业, 图来自 Wikipedia)

# 观察性研究



(ii) 观察性研究


## Assumption 1 (可忽略性, ignorability)

$$A \perp\!\!\!\perp (Y_0, Y_1) \mid L.$$

- $\text{pr}(A \mid L, Y_0, Y_1) = \text{pr}(A \mid L).$
- 在协变量的每个分层下，处理分配机制可以被视为随机化.
- 随机化试验也满足可忽略性假设.
- 可忽略性又被称作无混杂 (unconfoundedness) 假设，所有未观测的混杂不同时指向处理变量和结果变量.
- 该假设无法直接检验.

Rosenbaum & Rubin (1983) 提出的可忽略性假定是在观察性研究里评估因果作用最重要的假定.

# 观察性研究



(ii) 观察性研究


Rosenbaum & Rubin (1983) 提出的可忽略性假定是在观察性研究里评估因果作用最重要的假定。

## Assumption 2 (positivity, or overlap)

$$0 < \text{pr}(A = 1 \mid L) < 1.$$

- 上述概率  $e(l) = \text{pr}(A = 1 \mid L = l)$  常被称作倾向得分 (propensity score).
- 在协变量  $L$  的每一层里, 该假设都要求存在接受处理或接受对照的个体.
- 该假设可以直接检验.

## 可忽略性假设



(ii) 观察性研究

Rosenbaum & Rubin (1983) 提出的可忽略性假定是在观察性研究里评估因果作用最重要的假定。

### Assumption 3 (强可忽略性, strong ignorability)

(i)  $A \perp\!\!\!\perp (Y_0, Y_1) \mid L$ ; (ii)  $0 < \text{pr}(A = 1 \mid L) < 1$ .

在强可忽略性假定下, ATE 可以如下识别:

$$\begin{aligned}\tau &= E(Y_1 - Y_0) \\ &= E\{E(Y_1 - Y_0 \mid L)\} \\ &= E\{E(Y_1 \mid L)\} - E\{E(Y_0 \mid L)\} \\ &= E\{E(Y_1 \mid A = 1, L)\} - E\{E(Y_0 \mid A = 0, L)\} \\ &= E\{E(Y \mid A = 1, L)\} - E\{E(Y \mid A = 0, L)\}.\end{aligned}$$

如果不对混杂因素  $L$  进行调整, 将会导致有偏估计。



当  $L$  是离散取值时, 假设取值范围为  $L = 1, \dots, K$ .

$$\begin{aligned}\tau &= E(Y_1 - Y_0) \\ &= E\{E(Y | A = 1, L)\} - E\{E(Y | A = 0, L)\} \\ &= \sum_{k=1}^K \underbrace{E(Y | A = 1, L = k)}_{\mu(1, k)} \text{pr}(L = k) - \sum_{k=1}^K \underbrace{E(Y | A = 0, L = k)}_{\mu(0, k)} \text{pr}(L = k).\end{aligned}$$

- 首先,  $\mu(a, k)$  可以如下估计:  $\hat{\mu}(a, k) = \frac{\sum_{i=1}^n Y_i \delta(A_i = a, L_i = k)}{\sum_{i=1}^n \delta(A_i = a, L_i = k)}$ , 其中  $\delta(\cdot)$  表示示性函数.
- 其次,  $\text{pr}(L = k)$  可以如下估计:  $\hat{\text{pr}}(L = k) = \frac{\sum_{i=1}^n \delta(L_i = k)}{n}$ .
- 最后, 我们估计 ATE 如下,

$$\hat{\tau} = \sum_{k=1}^K \hat{\mu}(1, k) \hat{\text{pr}}(L = k) - \sum_{k=1}^K \hat{\mu}(0, k) \hat{\text{pr}}(L = k).$$

当  $L$  是维度很高或者连续时, 我们可以建立参数模型来估计因果作用.

# Yule-Simpson 悖论

Department	All		Men		Women	
	Applicants	Admitted	Applicants	Admitted	Applicants	Admitted
A	933	64%	825	62%	108	82%
B	585	63%	560	63%	25	68%
C	918	35%	325	37%	593	34%
D	792	34%	417	33%	375	35%
E	584	25%	191	28%	393	24%
F	714	6%	373	6%	341	7%
Total	4526	39%	2691	45%	1835	30%

$$\hat{E}(Y_1) = \underbrace{0.62}_{\hat{\mu}(1,1)} \times \underbrace{\frac{933}{4526}}_{\hat{\text{pr}}(L=1)} + \underbrace{0.63}_{\hat{\mu}(1,2)} \times \underbrace{\frac{585}{4526}}_{\hat{\text{pr}}(L=2)} + \dots + \underbrace{0.06}_{\hat{\mu}(1,6)} \times \underbrace{\frac{714}{4526}}_{\hat{\text{pr}}(L=6)} = 0.39.$$

$$\hat{E}(Y_0) = \underbrace{0.82}_{\hat{\mu}(0,1)} \times \underbrace{\frac{933}{4526}}_{\hat{\text{pr}}(L=1)} + \underbrace{0.68}_{\hat{\mu}(0,2)} \times \underbrace{\frac{585}{4526}}_{\hat{\text{pr}}(L=2)} + \dots + \underbrace{0.07}_{\hat{\mu}(0,6)} \times \underbrace{\frac{714}{4526}}_{\hat{\text{pr}}(L=6)} = 0.43.$$

$$\hat{\tau} = \hat{E}(Y_1) - \hat{E}(Y_0) = -0.04$$

Association Does Not Imply Causation!

## 回归估计 (Outcome regression model)

- 在给定可忽略性假定下, ATE 可以如下识别:

$$\begin{aligned}\tau &= E(Y_1 - Y_0) \\ &= E\{\underbrace{E(Y | A = 1, L)}_{\mu(1, L)}\} - E\{\underbrace{E(Y | A = 0, L)}_{\mu(0, L)}\}.\end{aligned}$$

- 上述识别表达式启发我们可以如下估计 ATE:

$$\hat{\tau}_{\text{reg}} = \frac{1}{n} \sum_{i=1}^n \{\hat{\mu}(1, L_i) - \hat{\mu}(0, L_i)\},$$

上式常被称为回归估计量, 其中  $\hat{\mu}(A, L)$  是结果变量模型  $\mu(A, L) = E(Y | A, L)$  的估计. 我们可以对  $\mu(A, L)$  建立回归模型  $\mu(A, L; \alpha)$ , 并通过如下矩约束条件求解参数  $\hat{\alpha}$ ,

$$E\{Y - \mu(A, L; \hat{\alpha}) | A, L\} = 0.$$

值得注意的是, 当  $\mu(A, L; \alpha)$  被错误指定时,  $\hat{\tau}_{\text{reg}}$  并不能相合估计  $\tau$ .

## 逆概加权估计 (Inverse probability weighted, IPW)

- 在给定可忽略性假定下, ATE 也可以如下识别:

$$\begin{aligned}\tau &= E(Y_1 - Y_0) \\ &= E\{E(Y | A = 1, L)\} - E\{E(Y | A = 0, L)\} \\ &= E\left\{\frac{AY}{e(L)}\right\} - E\left\{\frac{(1-A)Y}{1-e(L)}\right\},\end{aligned}$$

其中  $e(L) = \text{pr}(A = 1 | L)$  是倾向得分 (propensity score).

- 我们可以如下估计 ATE:

$$\hat{\tau}_{ipw} = \frac{1}{n} \sum_{i=1}^n \left\{ \frac{A_i Y_i}{\hat{e}(L_i)} - \frac{(1 - A_i) Y_i}{1 - \hat{e}(L_i)} \right\},$$

上式被称为逆概加权估计量, 其中  $\hat{e}(L_i)$  是倾向得分  $e(L_i) = \text{pr}(A_i = 1 | L_i)$  的估计.

## 逆概加权估计 (Inverse probability weighted, IPW)

IPW 估计相当于对样本做了权重调整,

$$\hat{\tau}_{\text{ipw}} = \frac{1}{n} \sum_{i=1}^n \left\{ \frac{A_i Y_i}{\hat{e}(L_i)} - \frac{(1 - A_i) Y_i}{1 - \hat{e}(L_i)} \right\},$$

对于处理组的个体  $i$ , 我们采用权重  $\hat{e}(L_i)^{-1}$  进行调整.

对于对照组的个体  $i$ , 我们采用权重  $\{1 - \hat{e}(L_i)\}^{-1}$  进行调整.

- 当  $L$  是离散或维数较低时, 我们可以采用非参数估计等方法估计  $\hat{e}(L)$ .
- 当  $L$  维数较高时, 我们可以采用对  $e(L) = \text{pr}(A = 1 \mid L)$  建立参数模型  $e(L; \beta)$ , 并通过极大似然估计或矩估计等方法求解参数  $\hat{\beta}$ .

值得注意的是, 当  $e(L; \beta)$  被错误指定时,  $\hat{\tau}_{\text{ipw}}$  并不能相合估计  $\tau$ .

- Hirano et al. (2003) 指出在 IPW 估计时, 采用非参数估计的倾向得分  $\hat{e}(L)$  将比使用正确的倾向得分的  $e(L)$  具有更小的渐进方差.

## 逆概加权估计 (Inverse probability weighted, IPW)

- 倾向评分一个众所周知的结果: 使用估计的倾向评分通常比真实的倾向评分有更好的 ATE 的估计 (Rosenbaum, 1987).
- Rosenbaum (1987, pp 391) 给出了一些直观的解释:

“ the same reason that covariate adjustment in RCT outperforms the unadjusted difference-in-means estimator –estimated PS corrects for chance imbalance in the sample, but true PS does not. ”
- Hirano et al. (2003) 指出在 IPW 估计时, 采用非参数估计的倾向得分  $\hat{e}(L)$  将比使用正确的倾向得分的  $e(L)$  具有更小的渐进方差.

## 双稳健估计 (Doubly robust estimation)

- 当所需要的回归模型不正确时,  $\hat{\tau}_{\text{reg}}$  将产生较大的偏差.
- 当所需要的倾向得分模型不正确时,  $\hat{\tau}_{\text{ipw}}$  将产生较大的偏差.
- 双稳健估计结合了回归估计与逆概加权估计的优点, 能有效缓解任一模型误设导致的偏差.

$$\begin{aligned}\hat{\tau}_{\text{dr}} = & \frac{1}{n} \sum_{i=1}^n \left[ \frac{A_i \{Y_i - \mu(1, L_i; \hat{\alpha})\}}{e(L_i; \hat{\beta})} + \mu(1, L_i; \hat{\alpha}) \right] \\ & - \frac{1}{n} \sum_{i=1}^n \left[ \frac{(1 - A_i) \{Y_i - \mu(0, L_i; \hat{\alpha})\}}{1 - e(L_i; \hat{\beta})} + \mu(0, L_i; \hat{\alpha}) \right].\end{aligned}$$

上述  $\hat{\tau}_{\text{dr}}$  估计量有两个等价的数学表示, 进而揭示了  $\hat{\tau}_{\text{dr}}$  的**双稳健**性质.

## 双稳健估计 (Doubly robust estimation)

当回归模型  $\mu(A_i, L_i; \alpha)$  被正确指定时, 我们可以得到  $\alpha$  的相合估计量  $\hat{\alpha}$ .

$$\begin{aligned} \hat{\tau}_{\text{dr}} = & \underbrace{\frac{1}{n} \sum_{i=1}^n \mu(1, L_i; \hat{\alpha}) - \frac{1}{n} \sum_{i=1}^n \mu(0, L_i; \hat{\alpha})}_{\hat{\tau}_{\text{reg}} \xrightarrow{P} \tau} \\ & + \underbrace{\frac{1}{n} \sum_{i=1}^n \frac{A_i}{e(L_i; \hat{\beta})} \{\mu(1, L_i; \hat{\alpha}) - Y_i\}}_{\xrightarrow{P} E\left[\frac{A_i}{e(L_i; \beta^*)} \{\mu(1, L_i; \alpha^*) - Y_i\}\right] = 0} - \underbrace{\frac{1}{n} \sum_{i=1}^n \frac{1 - A_i}{1 - e(L_i; \hat{\beta})} \{\mu(0, L_i; \hat{\alpha}) - Y_i\}}_{\xrightarrow{P} E\left[\left\{\frac{1 - A_i}{1 - e(L_i; \beta^*)}\right\} \{\mu(0, L_i; \alpha^*) - Y_i\}\right] = 0} \end{aligned}$$

其中  $\alpha^*$  和  $\beta^*$  分别表示当样本量趋于无穷时  $\hat{\alpha}$  和  $\hat{\beta}$  依概率收敛的极限值. 注意到, 当回归模型  $\mu(A_i, L_i; \alpha)$  被正确指定时, 无论倾向得分模型  $e(L_i; \beta)$  正确指定与否, 我们都有

$$E\left[\frac{A_i}{e(L_i; \beta^*)} \{\mu(1, L_i; \alpha^*) - Y_i\}\right] = E\left[\underbrace{E\{\mu(1, L_i; \alpha^*) - Y_i \mid A_i = 1, L_i\}}_{=0} \frac{A_i}{e(L_i; \beta^*)}\right] = 0.$$



## 双稳健估计 (Doubly robust estimation)

当倾向得分模型  $e(L_i; \beta)$  被正确指定时, 我们可以得到  $\beta$  的相合估计量  $\hat{\beta}$ .

$$\begin{aligned} \hat{\tau}_{\text{dr}} = & \underbrace{\frac{1}{n} \sum_{i=1}^n \frac{A_i}{e(L_i; \hat{\beta})} Y_i - \frac{1}{n} \sum_{i=1}^n \frac{1 - A_i}{1 - e(L_i; \hat{\beta})} Y_i}_{\hat{\tau}_{\text{ipw}} \xrightarrow{P} \tau} \\ & + \underbrace{\frac{1}{n} \sum_{i=1}^n \left\{ 1 - \frac{A_i}{e(L_i; \hat{\beta})} \right\} \mu(1, L_i; \hat{\alpha})}_{\xrightarrow{P} E \left[ \left\{ 1 - \frac{A_i}{e(L_i; \beta^*)} \right\} \mu(1, L_i; \alpha^*) \right] = 0} - \underbrace{\frac{1}{n} \sum_{i=1}^n \left\{ 1 - \frac{1 - A_i}{1 - e(L_i; \hat{\beta})} \right\} \mu(0, L_i; \hat{\alpha})}_{\xrightarrow{P} E \left[ \left\{ 1 - \frac{1 - A_i}{1 - e(L_i; \beta^*)} \right\} \mu(0, L_i; \alpha^*) \right] = 0}. \end{aligned}$$

其中  $\alpha^*$  和  $\beta^*$  分别表示当样本量趋于无穷时  $\hat{\alpha}$  和  $\hat{\beta}$  依概率收敛的极限值. 注意到, 当倾向得分模型  $e(L_i; \beta)$  被正确指定时, 回归模型  $\mu(A_i, L_i; \alpha)$  无论正确指定与否, 我们都有

$$E \left[ \left\{ 1 - \frac{A_i}{e(L_i; \beta^*)} \right\} \mu(1, L_i; \alpha^*) \right] = E \left[ \underbrace{E \left[ \frac{e(L_i; \beta^*) - A_i}{e(L_i; \beta^*)} \middle| L_i \right]}_{=0} \mu(1, L_i; \alpha^*) \right] = 0.$$

# 双稳健估计

- 当任一模型正确指定时, 双稳健估计仍具有相合估计.
- 当两个模型都不正确时, 双稳健估计可能会带来比回归和逆概加权估计更大的偏差 (Kang & Schafer, 2007).
- 双稳健估计量在近些年得到了广泛的应用.

# 稳健估计

- 在可忽略性假定不满足的时候, 许多文献也建立 ATE 的识别性, 并在不同的识别假设下考虑了 ATE 的稳健估计.
- 值得注意的是, 许多稳健估计量需要的模型通常难以正确指定.
- 除了参数模型之外, 许多非参数的方法也被用于稳健估计.

# 机器学习的一些方法

- 机器学习模型经常用于预测，并不能直接用于预测反事实结果 (这是因果推断关心的).
- 机器学习的一些重要思想：
  - Sample splitting, 以便构建模型和估计因果作用.
  - Double learning, 分别学习倾向得分和结果变量模型，并结合两个模型的优势用于因果推断.
  - Cross-fitting, 数据交叉验证来控制偏差和方差.
- 一些有代表性的工作：
  - 因果树和因果森林 (Causal trees and forest, Wager & Athey, 2018).
  - 双重机器学习 (Double/debiased machine learning, Chenozhukov et al., 2018).
  - BART (Bayesian additive regression trees, Chipman et al., 2010).
- 机器学习的方法仍不能解决因果推断的一些基本问题，例如可忽略性假定.

我们评估  $\hat{\tau}_{\text{reg}}$ ,  $\hat{\tau}_{\text{ipw}}$  以及  $\hat{\tau}_{\text{dr}}$  的有限样本表现.

- $L \sim N(0, 1)$
- $\text{pr}(A = 1 \mid L) = \text{expit}(0.5L - 0.2L^2) \Rightarrow e(L) = \text{expit}(\beta_0 + \beta_1 L + \beta_2 L^2)$
- $Y = 1.5A + 2L + L^2 + \varepsilon, \varepsilon \sim N(0, 1) \Rightarrow \mu(A, L) = \alpha_0 + \alpha_1 A + \alpha_2 L + \alpha_3 L^2$

Case 1: 所有模型都被正确指定, 即

$$e(L; \beta) = e(L); \quad \mu(A, L; \alpha) = \mu(A, L).$$

Case 2: 回归模型被正确指定, 倾向得分被错误指定, 即

$$e(L; \beta) = \text{expit}(\beta_0 + \beta_1 L); \quad \mu(A, L; \alpha) = \mu(A, L).$$

Case 3: 倾向得分模型被正确指定, 回归模型被错误指定, 即


$$e(L; \beta) = \text{expit}(L); \quad \mu(A, L; \alpha) = \alpha_0 + \alpha_1 A + \alpha_2 L.$$

Case 4: 所有模型都被错误指定, 即


$$e(L; \beta) = \text{expit}(\beta_0 + \beta_1 L); \quad \mu(A, L; \alpha) = \alpha_0 + \alpha_1 A + \alpha_2 L.$$

# 稳健估计


Both models are correct




Only outcome regression model is correct




Only propensity score model is correct




Both models are incorrect



## 倾向得分重要的性质



(i)



(ii)

### 定理 1 (倾向得分定理, Rosenbaum & Rubin (1983))

在可忽略性假设下, 即

$$(i) A \perp\!\!\!\perp (Y_0, Y_1) \mid L; \quad 0 < \text{pr}(A = 1 \mid L) < 1,$$

$$\implies (ii) A \perp\!\!\!\perp (Y_0, Y_1) \mid e(L); \quad 0 < \text{pr}\{A = 1 \mid e(L)\} < 1.$$

平衡得分 (balancing score), 降维 (dimension reduction), 分层 (stratification), 匹配 (matching)...

## 倾向得分重要的性质

### 证明.

我们只要证明

$$\text{pr}(A = 1 \mid Y_1, e(L)) = \text{pr}(A = 1 \mid e(L))$$

$$\begin{aligned}\text{pr}(A = 1 \mid Y_1, e(L)) &= \mathbb{E}\{A \mid Y_1, e(L)\} \\ &= \mathbb{E}[\mathbb{E}\{A \mid Y_1, e(L), L\} \mid Y_1, e(L)] \\ &= \mathbb{E}\{\mathbb{E}(A \mid Y_1, L) \mid Y_1, e(L)\} \\ &= \mathbb{E}\{\mathbb{E}(A \mid L) \mid Y_1, e(L)\} \\ &= \mathbb{E}\{e(L) \mid Y_1, e(L)\} \\ &= e(L) \\ &= \text{pr}(A = 1 \mid e(L))\end{aligned}$$

其中最后一个等式是由于





## 倾向得分重要的性质

### 证明.

我们有  $\text{pr}\{A = 1 \mid L, e(L)\} = \text{pr}(A = 1 \mid L) = e(L)$ , 及

$$\text{pr}\{A = 1 \mid e(L)\} = E[\text{pr}\{A = 1 \mid L, e(L)\} \mid e(L)] = E\{e(L) \mid e(L)\} = e(L)$$

因此,  $\text{pr}\{A = 1 \mid L, e(L)\} = \text{pr}\{A = 1 \mid e(L)\}$ , 即  $L \perp\!\!\!\perp A \mid e(L)$ . □

## 匹配 (Matching)

- 通过回归估计模型,

对于处理组的个体  $i$ , 我们使用  $\hat{\mu}(0, L_i)$  “填补” 个体  $i$  在接受对照时的潜在结果  $Y_i(0)$ .

对于对照组的个体  $i$ , 我们使用  $\hat{\mu}(1, L_i)$  “填补” 个体  $i$  在接受治疗时的潜在结果  $Y_i(1)$ .

- 我们考虑匹配估计,

对于处理组的个体  $i$ , 我们可以在对照组里找与  $L_i$  最接近的个体的结果用于“填补” 个体  $i$  在接受对照时的潜在结果  $Y_i(0)$ .

对于对照组的个体  $i$ , 我们可以在处理组里找与  $L_i$  最接近的个体的结果用于“填补” 个体  $i$  在接受治疗时的潜在结果  $Y_i(1)$ .

- 匹配的目的 在于平衡处理组和对照组协变量的分布.
- 匹配的思想也可用于估计 ATT 和 ATC.

## 最近邻匹配

个体  $i$  根据  $L_2$  范数匹配的集合定义为:

$$J_M(i) = \left\{ j = 1, \dots, n : A_j = 1 - A_i \text{ and } \sum_{k: A_k = 1 - A_i} \delta(\|L_i - L_k\| \leq \|L_i - L_j\|) \leq M \right\},$$

- 其中  $M$  为整数, 代表每一个个体的匹配数据的个数.
- $J_M(i)$  的定义允许在构造匹配集合过程中放回已被使用的个体, 不同的个体可以选择相同的协变量进行匹配.

我们可以如下估计 ATE:

$$\hat{\tau}_{\text{mat}} = \sum_{i=1}^n \frac{\hat{Y}_i(1)}{n} - \sum_{i=1}^n \frac{\hat{Y}_i(0)}{n},$$

上述估计量被称为匹配估计量, 其中

$$\hat{Y}_i(0) = \begin{cases} \frac{1}{M} \sum_{j \in J_M(i)} Y_j, & A_i = 1, \\ Y_i, & A_i = 0. \end{cases} \quad \hat{Y}_i(1) = \begin{cases} Y_i, & A_i = 1, \\ \frac{1}{M} \sum_{j \in J_M(i)} Y_j, & A_i = 0. \end{cases}$$

## 再谈匹配

- 当  $L$  维度比较高的时候, 使用高维协变量进行匹配会比较困难. 根据倾向得分定理, 我们可以使用倾向得分进行匹配,

$$J_M(i) = \left\{ j = 1, \dots, n : A_j = 1 - A_i \text{ and } \sum_{k: A_k = 1 - A_i} \delta(|e(L_i) - e(L_k)| \leq |e(L_i) - e(L_j)|) \leq M \right\}.$$

- 我们可以如下估计 ATE: 
$$\hat{\tau}_{\text{mat}} = \sum_{i=1}^n \frac{\hat{Y}_i(1)}{n} - \sum_{i=1}^n \frac{\hat{Y}_i(0)}{n},$$

其中

$$\hat{Y}_i(0) = \begin{cases} \frac{1}{M} \sum_{j \in J_M(i)} Y_j, & A_i = 1, \\ Y_i, & A_i = 0. \end{cases} \quad \hat{Y}_i(1) = \begin{cases} Y_i, & A_i = 1, \\ \frac{1}{M} \sum_{j \in J_M(i)} Y_j, & A_i = 0. \end{cases}$$

- Abadie & Imbens (2006, 2016) 讨论了上述估计量的渐进性质.

## 再谈处理组的因果效应

- 由定义, ATE, ATT 和 ATC 三者的关系如下:


$$\tau = \text{pr}(A = 1) \tau_{\text{ATT}} + \text{pr}(A = 0) \tau_{\text{ATC}}$$

- 在随机化下, 我们有  $\text{ATE} = \text{ATT} = \text{ATC}$ , 因为

$$\underbrace{E(Y_1 - Y_0)}_{\tau} = \underbrace{E(Y_1 - Y_0 \mid A = 1)}_{\tau_{\text{ATT}}} = \underbrace{E(Y_1 - Y_0 \mid A = 0)}_{\tau_{\text{ATC}}}$$

- 在观察性研究中, ATE 一般和 ATT 与 ATC 是不同的.
- 我们接下来讨论 ATT 的识别条件, ATC 类似.

## 处理组的因果效应



(ii) 观察性研究

当我们在讨论 ATT 的识别性时,  
可忽略性和 positivity 假设都可以  
被放松.

### Assumption 4 (可忽略性, ignorability)

(i)  $A \perp\!\!\!\perp Y_0 \mid L$ ; (ii)  $\text{pr}(A = 1 \mid L) < 1$ .

在上述可忽略性假定下, ATT 可以如下识别:

$$\begin{aligned}\tau_{\text{ATT}} &= E(Y_1 - Y_0 \mid A = 1) \\ &= E(Y_1 \mid A = 1) - E\{E(Y_0 \mid A = 1, L) \mid A = 1\} \\ &= E(Y \mid A = 1) - E\{E(Y_0 \mid A = 1, L) \mid A = 1\} \\ &= E(Y \mid A = 1) - E\{E(Y_0 \mid A = 0, L) \mid A = 1\} \\ &= E(Y \mid A = 1) - E\{E(Y \mid A = 0, L) \mid A = 1\}.\end{aligned}$$

## 本周作业

- ① 证明逆概加权识别表达式
- ② 上机作业：计算所给数据的回归估计量，逆概加权估计量，双稳健估计量
- ③ 附加题：验证双稳健估计量的双稳健性质，可参考文献：  
Tsiatis, A. A. (2006). Semiparametric theory and missing data. Springer. P147-150.
- ④ 上机作业要求用 Rmarkdown 输出 pdf，注意注释及格式
- ⑤ 作业扫描成 pdf 发邮箱:smengchen@163.com